

Tecnológico de Costa Rica
Escuela de Ingeniería Electrónica
Programa de Licenciatura en Ingeniería Electrónica



**Diseño e implementación de un controlador basado en
aprendizaje reforzado sobre una planta prototipo de control
automático**

Informe de Trabajo Final de Graduación para optar por el título de
Ingeniero en Electrónica con el grado académico de Licenciatura

Jorge Andrés Brenes Alfaro

Borrador de 8 de julio de 2022

Declaro que los resultados obtenidos en el presente trabajo de investigación, previo a la obtención del título de Licenciado en Ingeniería en Electrónica, son absolutamente originales, auténticos y personales.

Soy consciente de que el hecho de no respetar los derechos de autor y realizar una mala conducta científica; es decir, fabricación de datos falsos y plagio, conlleva sanciones universitarias y/o legales.

En tal virtud, declaro que el trabajo de investigación realizado sujeto a evaluación no ha sido presentado anteriormente para obtener algún grado académico o título, ni ha sido publicado en sitio alguno y los efectos legales y académicos que se puedan derivar del trabajo propuesto de investigación son y serán de mi sola y exclusiva responsabilidad legal y académica.

Jorge Andrés Brenes Alfaro

Cartago, 8 de julio de 2022

Céd: 3-0514-0729

Instituto Tecnológico de Costa Rica
Escuela de Ingeniería Electrónica
Proyecto de Graduación
Acta de Aprobación

Defensa de Proyecto de Graduación
Requisito para optar por el título de Ingeniero en Electrónica
Grado Académico de Licenciatura

El Tribunal Evaluador aprueba la defensa del proyecto de graduación denominado *Diseño e implementación de un controlador basado en aprendizaje reforzado sobre una planta prototipo de control automático*, realizado por el señor Jorge Andrés Brenes Alfaro y, hace constar que cumple con las normas establecidas por la Escuela de Ingeniería Electrónica del Instituto Tecnológico de Costa Rica.

Miembros del Tribunal Evaluador

Dra. María del Pilar Pérez Revuelta
Profesora Lectora

M.Sc. Juan Pérez Hernández
Profesor Lector

Ing. Albert Einstein Sánchez
Profesor Asesor

Cartago, 8 de julio de 2022

Instituto Tecnológico de Costa Rica
Escuela de Ingeniería Electrónica
Trabajo Final de Graduación
Tribunal Evaluador
Acta de Evaluación

Defensa de Trabajo Final de Graduación
Requisito para optar por el título de Ingeniero en Electrónica
Grado Académico de Licenciatura

Estudiante: **Jorge Andrés Brenes Alfaro** Carné: 2017101058

Nombre del proyecto: *Diseño e implementación de un controlador basado en aprendizaje reforzado sobre una planta prototipo de control automático*

Los miembros de este Tribunal hacen constar que este proyecto de graduación ha sido aprobado y cumple con las normas establecidas por la Escuela de Ingeniería Electrónica del Instituto Tecnológico de Costa Rica y es merecedor de la siguiente calificación:

Nota de Trabajo Final de Graduación: _____

Miembros del Tribunal Evaluador

Dra. María del Pilar Pérez Revuelta
Profesora Lectora

M.Sc. Juan Pérez Hernández
Profesor Lector

Ing. Albert Einstein Sánchez
Profesor Asesor

Cartago, 8 de julio de 2022

Resumen

Palabras clave: palabras, clave, ...

Abstract

Keywords: word 1, word 2,

a mis queridos padres

Agradecimientos

El resultado de este trabajo no hubiese sido posible sin el apoyo de ...

Jorge Andrés Brenes Alfaro

Cartago, 8 de julio de 2022

Índice general

Índice de figuras	II
Índice de tablas	III
Revisar	IV
1. Introducción	1
1.1. Objetivos y estructura del documento	4
2. Marco teórico	5
3. Controlador basado en aprendizaje reforzado	6
4. Resultados y análisis	7
5. Conclusiones	8
Bibliografía	9

Índice de figuras

1.1. Interacción del aprendizaje reforzado.	2
1.2. Diagrama de primer nivel para la estrategia del control de un sistema no lineal.	3

Índice de tablas

Revisar

No mencionar la PAHM en la intro, mejor aquí que trata de mi solución que se realiza el trabajo con una planta PAHM

Lista de símbolos y abreviaciones

Abreviaciones

PAHM	Péndulo Amortiguado a Hélice
RL	Aprendizaje Reforzado
RNA	Redes Neuronales Artificiales

Capítulo 1

Introducción

Actualmente, el control automático tiene un papel vital en el avance de la ciencia y de la ingeniería, siendo parte fundamental en la economía global, puesto que, gran parte de los procesos industriales y de manufactura moderna se encuentran automatizados [1]. Esto ha radicado en la reducción de costos, del consumo de energía y tiempo, y el incremento en la calidad y volumen de producción. Además, el logro de una vida con mayores comodidades, la eliminación de errores y aumento en la seguridad de los procesos. Gracias a ello, ésta área ha llevado a impulsar la tecnología, el desarrollo y aplicación de técnicas modernas de control, impulsando así, avances científicos y tecnológicos [2].

Sin embargo, en sistemas de control, al modelar la planta surge el problema de tener un proceso descrito por un modelo o sistema de ecuaciones regido por una variable de estado dependiente del tiempo, donde ésta representa el comportamiento o dinámica de algún proceso determinado y es requerido para que el proceso se desempeñe de forma eficiente [2]. La dinámica del modelo puede convertirse en una tarea muy compleja al ser un sistema no lineal; es decir, que su salida no es proporcional a los cambios realizados en la(s) entradas(s). Donde la mayoría de los sistemas dinámicos que se encuentran en la naturaleza son no lineales [3], y problemas recientes que se pueden observar en aplicaciones modernas de ingeniería son: sistemas de comando de vuelo, manipuladores de robot, sistemas de inyección de combustible de alto rendimiento, entre otros [4]. Por lo que se vuelve de importancia algún método o técnica para identificar el sistema, aunque no hay método fijo debido a esta propiedad de no linealidad.

Los controladores convencionales utilizados hasta el momento son buenos siempre y cuando la planta sea linealizable en los puntos de operación, ya que para controlar un sistema se busca elegir un punto de operación; no obstante, para aquellos sistemas donde existen puntos de operación variantes en el tiempo o no linealidades en su modelo, la capacidad de controlar el sistema se complica [5].

Es común encontrar en la industria dificultades al control de sistemas dinámicos complejos, pues tienen fenómenos no lineales que no pueden ser descritos mediante dinámica de modelos lineales [4], cuya metodología es parte del desarrollo de controladores en el

control clásico. Además, existen perturbaciones impredecibles que afectan el desempeño de los controladores, siendo la implementación del control clásico no 100 % efectivo [6]. En consecuencia, los sistemas clásicos de control no pueden manejar la no linealidad de los sistemas y surge la necesidad de diseñar e implementar estrategias innovadoras de control automático para los procesos no lineales y controlar el sistema en todo su punto de operación .

En recientes años, ha habido un incremento en la aplicación de redes neuronales artificiales (RNA), las cuales son una excelente herramienta para el aprendizaje de relaciones complejas a partir de un conjunto de ejemplos. Además, debido a sus capacidades de aproximación, su adaptabilidad y su gran tolerancia a fallos, las redes neuronales artificiales presentan una importante alternativa en el modelado de sistemas no-lineales [7]. Por ello, se genera un interés del uso de estas mismas para la identificación y comportamiento de un sistema dinámico no lineal, donde a partir de la salida ante una entrada dada, la red sería capaz de modificar sus parámetros aprendiendo una aproximación de la dinámica del sistema hasta conseguir un sistema fiable [8] y [9].

Una alternativa que se ha vuelto muy popular, teniendo un alto crecimiento en los últimos años, es el aprendizaje reforzado (RL), el cual ofrece potentes algoritmos para buscar y desarrollar controladores óptimos de sistemas con dinámicas no lineales, estocásticos y que son desconocidas o muy inciertas [10]. Esta metodología busca que un agente sea capaz de encontrar la acción correcta de manera autónoma, explorando un espacio desconocido y determinando la acción mediante prueba y error. Dicho agente aprende por medio de recompensas y penalizaciones que obtiene de sus acciones, con el fin de actuar y crear la mejor estrategia posible, de forma que maximice la recompensa [11] y [12]. Esta interacción es representada en la figura 1.1.




Figura 1.1: Interacción del aprendizaje reforzado.

Gran parte de este enfoque se ha utilizado para resolver juegos de Atari, ejemplo de ello es el Alphago, cuya aplicación fue noticia a nivel global, ya que un algoritmo de RL fue capaz de vencer al campeón de Go. No obstante, también es utilizado en situaciones sistemas de control cuando control clásico no tiene la capacidad de lidiar con problemas y se

puede volver muy complejo, por ejemplo, el control de la suspensión de un automóvil ante terrenos irregulares, el vuelo autónomo de drones, locomoción robótica con extremidades, entre otros [11].

La solución desarrollada en este proyecto es una alternativa de introducir el aprendizaje reforzado y redes neuronales en el control automático, ya que esta metodología podría ajustar los cambios del sistema al tener que interactuar con las acciones, permitiendo automatizar más procesos y el control de sistemas no lineales. Para ello, se plantea el uso de dos redes neuronales artificiales, una que se comporte como el sistema de estudio, de forma que adquiera las características de este y lo aproxime lo mejor posible. Y otra que lleve a cabo el control del sistema por medio de aprendizaje reforzado.

Aprovechando así la capacidad de aproximación y adaptabilidad de las RNAs. Además de experimentar con diversas entradas, sin afectar directamente la planta, evitando el riesgo de que los primeros experimentos son tan violentos en los cambios que pueden dañar la planta. Permite tener una gran cantidad de muestras de salida que serán de gran utilidad para ejecutar el entrenamiento de la red utilizando el aprendizaje reforzado. Y por último, presenta un mejor tiempo de desarrollo, ya que con la ayuda de las RNA se puede prescindir de cálculos complejos, así como del planteamiento del modelo que se necesitaría para el control clásico, pues las RNA se puede adaptar a cualquier tipo de estructura sin necesidad de conocer sus características [8].

Dicha solución se puede ver representada con un diagrama de bloques de primer nivel en la figura 1.2, donde primeramente, se recopila datos de entrada y salida de la planta de PAHM para el entrenamiento de la RNA mimetizadora. Seguidamente, se implementa y se entrena la RNA mimetizadora. Por último, se desarrolla el controlador basado en aprendizaje reforzado y se prueba con la RNA mimetizadora, donde se puede evaluar el desempeño y posteriormente realizar la pruebas con la planta prototipo.

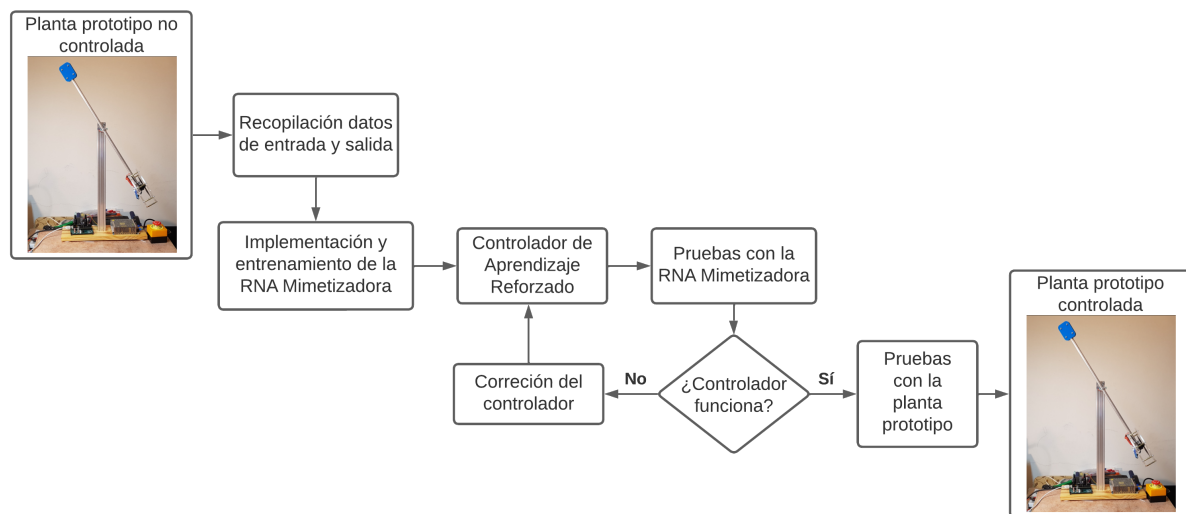


Figura 1.2: Diagrama de primer nivel para la estrategia del control de un sistema no lineal.

1.1. Objetivos y estructura del documento

El objetivo principal de este proyecto es desarrollar un sistema de control para una planta prototipo mediante el uso de aprendizaje reforzado. Asimismo, esta investigación se basa en cuatro objetivos específicos, donde el primero consiste en determinar el acople del sistema embebido de altas prestaciones al lazo de control. Como segundo objetivo se tiene el preparar un conjunto de datos para el entrenamiento de una red neuronal artificial. Donde la base de datos contenga millones de muestras en el tiempo para que la red neuronal tenga la suficiente información para entrenar el modelo. El tercer objetivo consiste en implementar una red neuronal artificial que mimetice el comportamiento del sujeto de estudio. Y el último es diseñar un sistema capaz de realizar la labor de control de la planta prototipo, a través de la implementación de aprendizaje reforzado, de modo que, se pueda estabilizar el sistema, con un sobreimpulso inferior al 5%, cero error de estado estacionario y la eliminación de perturbaciones de entrada o salida a la planta.

Este documento se constituye de los siguientes apartados: el capítulo 2 se describe en detalle el marco teórico, donde se esbozan los fundamentos teóricos necesarios para explicar la propuesta realizada. En el capítulo 3 se detalla la estrategia desarrollada y el modelo implementado para la solución del problema. En el capítulo 4 se lleva a cabo el análisis de los resultados obtenidos. Por último, el capítulo 5 se presenta las conclusiones de la investigación y trabajo realizado, así como recomendaciones y trabajo a futuro por desarrollar.

Capítulo 2

Marco teórico

Capítulo 3

Controlador basado en aprendizaje reforzado

No
mencionar la
PAHM en la
intro, mejor
aquí que
trata de mi
solución que
se realiza el
trabajo con
una planta
PAHM

Capítulo 4

Resultados y análisis

Capítulo 5

Conclusiones

Bibliografía

- [1] Á. Almidón Elescano y E. Julian-Laime, *Sistemas de Control Automático I- Teoría y problemas aplicativos*. 2018. DOI: [10.5281/zenodo.2560185](https://doi.org/10.5281/zenodo.2560185).
- [2] M. Alcorta García. «Impacto del control automático e inteligencia artificial.» (2019), dirección: <http://cienciauanl.uanl.mx/?p=9193%22> (visitado 09-03-2022).
- [3] H. Kapasi. «Modeling Non-Linear Dynamic Systems with Neural Networks.» (2022), dirección: <https://towardsdatascience.com/modeling-non-linear-dynamic-systems-with-neural-networks-f3761bc92649> (visitado 07-03-2022).
- [4] M. Serón, *Sistemas no lineales. Apuntes de clase*, 2001.
- [5] P. Alvarado, *(Comunicación Privada)*, 2022.
- [6] E. Sarmiento Jurado, «Diseño e implementación de un controlador basado en redes neuronales con entrenamiento rápido para sistemas de control 2x2,» Tesis de mtría., Universidad del Norte, Barranquilla, Colombia, 2006.
- [7] R. Valverde Gil y D. Gachet Páez, «Identificación de sistemas dinámicos utilizando redes neuronales,» *Revista Iberoamericana de Automática e Informática Industrial*, n.º 1697-7912, 2007.
- [8] S. Torrubia Caravaca, «Redes neuronales multimodelo aplicadas al control de sistema,» Tesis de mtría., Universidad Autónoma de Barcelona, España, 2010.
- [9] C. Møldrup Legaard, T. Schranz, G. Schweiger y col., «Constructing neural network-based models for simulating dynamical systems,» *ACM Computing Surveys*, vol. 1, n.º 1, 2021.
- [10] L. Busoniu, T. de Bruin, D. Tolic, J. Kober e I. Palunko, «Reinforcement learning for control: performance, stability, and deep approximators,» *Annual Reviews in Control*, vol. 46, 2018, ISSN: 1367-5788.
- [11] A. Díaz Latorre, «Aprendizaje por refuerzo para control de sistemas dinámicos,» Tesis de mtría., Universidad Autónoma de Occidente, Santiago de Cali, Colombia, 2019.
- [12] J. Torres, en *Introducción al aprendizaje por refuerzo profundo. Teoría y práctica en Python*. Publicación Independiente, 2021, Capítulo 1.